

FTML Exercices 3

15 mai 2026

TABLE DES MATIÈRES

1	Estimateurs et espérances	1
1.1	Moyenne empirique et espérance	1
1.2	Espérance du risque empirique d'un estimateur indépendant du dataset	1
1.3	Espérance du risque empirique du minimiseur du risque empirique	2

1 ESTIMATEURS ET ESPÉRANCES

Remarque : attention, le terme estimateur est utilisé avec deux sens différents ici :

— Estimateur statistique

[https://fr.wikipedia.org/wiki/Estimateur_\(statistique\)](https://fr.wikipedia.org/wiki/Estimateur_(statistique))

— Estimateur au sens "modèle" : fonction utilisée pour prédire en fonction d'une entrée x .

1.1 Moyenne empirique et espérance

1) On se donne une variable aléatoire réelle X ayant un moment d'ordre 1. On note $E[X]$ son espérance. On suppose que l'on dispose de n samples indépendants tirés de cette variable, $(x_1, \dots, x_n)$, qui suivent donc la loi de X . On considère leur moyenne empirique $S_n = \frac{1}{n} \sum_{i=1}^n x_i$. Montrer que l'espérance de S_n est l'espérance de X , $E[X]$ (autrement dit, que S_n est un estimateur non biaisé de $E[X]$).

2) Simuler une variable de votre choix pour observer la convergence de S_n vers $E[X]$.

1.2 Espérance du risque empirique d'un estimateur indépendant du dataset

1) On se donne un problème d'apprentissage supervisé usuel et un estimateur f , fixé et indépendant du dataset. Montrer que l'espérance du risque empirique de f est le risque réel de f . Autrement dit : le risque empirique de f est un estimateur non biaisé de son risque réel.

La notion d'espérance a bien un sens ici car il faut voir le dataset comme une variable aléatoire, ainsi le risque empirique de f est bien une variable aléatoire.

2) Simuler un problème de votre choix pour observer le résultat (c'est ce qui est fait dans `simulations/lecture_3/empirical_risk_convergence`)

1.3 Espérance du risque empirique du minimiseur du risque empirique

Montrer que le résultat précédent n'est plus vrai quand f est le minimiseur du risque empirique, c'est-à-dire la fonction f_n pour laquelle le risque empirique prend la valeur la plus faible. On note que maintenant, f_n est une variable aléatoire, calculée à partir du dataset.

Remarque : vous pouvez montrer le résultat par le calcul mais également le vérifier en faisant des simulations.

Remarque : Ce fait est une autre façon de dire qu'il est possible d'overfitter.