FTML Exercices 3

17 mai 2026

TABLE DES MATIÈRES

1 Estimateurs et espérances 1
1.1 Moyenne empirique et espérance 1
1.2 Espérance du risque empirique d'un estimateur indépendant du dataset 1
1.3 Espérance du risque empirique du minimiseur du risque empirique . 2

1 ESTIMATEURS ET ESPÉRANCES

Remarque : attention, le terme estimateur est utilisé avec deux sens différents ici :

— Estimateur statistique
https://fr.wikipedia.org/wiki/Estimateur_(statistique)

— Estimateur au sens "modèle" : fonction utilisée pour prédire en fonction d'une entrée x.

1.1 Moyenne empirique et espérance

1) On se donne une variable aléatoire réelle X ayant un moment d'ordre 1. On note $E[X]$ son espérance. On suppose que l'on dispose de n samples indépendants tirés de cette variable, $(x_1, \ldots, x_n)$, qui suivent donc la loi de X. On considère leur moyenne empirique $S_n = \frac{1}{n}\sum_{i=1}^{n} x_i$. Montrer que l'espérance de S_n est l'espérance de X, $E[X]$ (autrement dit, que S_n est un estimateur non biaisé de $E[X]$).

2) Simuler une variable de votre choix pour observer la convergence de S_n vers $E[X]$.

1.2 Espérance du risque empirique d'un estimateur indépendant du dataset

1) On se donne un problème d'apprentissage supervisé usuel et un estimateur f, fixé et indépendant du dataset. Montrer que l'espérance du risque empirique de f est le risque réel de f. Autrement dit : le risque empirique de f est un estimateur non biaisé de son risque réel.
La notion d'espérance a bien un sens ici car il faut voir le dataset comme une variable aléatoire, ainsi le risque empirique de f est bien une variable aléatoire.

2) Simuler un problème de votre choix pour observer le résultat (c'est ce qui est fait dans simulations/lecture_3/empirical_risk_convergence)

1.3 Espérance du risque empirique du minimiseur du risque empirique

Montrer que le résultat précédent n'est plus vrai quand f est le minimiseur du risque empirique, c'est-à-dire la fonction f_n pour laquelle le risque empirique prend la valeur la plus faible. On note que maintenant, f_n est une variable aléatoire, calculée à partir du dataset.

Remarque : vous pouvez montrer le résultat par le calcul mais également le vérifier en faisant des simulations.

Remarque : Ce fait est une autre façon de dire qu'il est possible d'overfitter.